


实验1： K近邻算法

实验2： 决策树


k近邻算法的基本原理

- 给定一个训练数据集
- 对于新的输入实例，在数据集中找到与该实例**最邻近的k个实例**
- 这k个实例中的**多数的类别**作为该输入实例的类



距离度量

- 样本 $x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})^T$
- Lp距离 $L_p(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^p \right)^{\frac{1}{p}}$
- $p = 2$, 欧式距离 $L_2(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^2 \right)^{\frac{1}{2}}$
- $p = 1$, 曼哈顿距离 $L_1(x_i, x_j) = \sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|$
- $p = \infty$, 切比雪夫距离 $L_\infty(x_i, x_j) = \max_l |x_i^{(l)} - x_j^{(l)}|$



- 有下列样本：
- $x^{(1)} = [1,0]$, $x^{(2)} = [3,0]$, $x^{(3)} = [0,3]$, $x^{(4)} = [-2,-2]$,
- $x^{(5)} = [2,0]$, $x^{(6)} = [1,1]$, $x^{(7)} = [1,2]$, $x^{(8)} = [0,0]$
- 已知 $x^{(1)}, x^{(2)}, x^{(3)}, x^{(4)}$ 属于类别A, $x^{(5)}, x^{(6)}, x^{(7)}$ 属于类别B。
- 计算样本 $x^{(8)}$ 到其他样本的欧式距离
- 使用K近邻算法, 距离采用欧式距离, 令K=1, 预测 $x^{(8)}$ 的类别

- $x^{(1)} = [1,0]$, $x^{(2)} = [3,0]$, $x^{(3)} = [0,3]$, $x^{(4)} = [-2,-2]$,
- $x^{(5)} = [2,0]$, $x^{(6)} = [1,1]$, $x^{(7)} = [1,2]$, $x^{(8)} = [0,0]$

$x^{(1)}, x^{(2)}, x^{(3)}, x^{(4)}$ 属于类别A, $x^{(5)}, x^{(6)}, x^{(7)}$ 属于类别B

1. 计算待预测样本 $x^{(8)}$ 与训练样本的欧式距离

- $d_{18} = 1$, $d_{28} = 3$, $d_{38} = 3$, $d_{48} = 2\sqrt{2} = 2.828$,
- $d_{58} = 2$, $d_{68} = \sqrt{2} = 1.414$, $d_{78} = \sqrt{5} = 2.236$

2. 排序: $d_{18} < d_{68} < d_{58} < d_{78} < d_{48} < d_{28} = d_{38}$

3. 取前k(=1)个距离最近样本, 统计其类别: 样本1, 类别为A

4. 将占比最多的类别赋给待预测样本: 类别A

- 有下列样本：
- $x^{(1)} = [1,0]$, $x^{(2)} = [3,0]$, $x^{(3)} = [0,3]$, $x^{(4)} = [-2,-2]$,
- $x^{(5)} = [2,0]$, $x^{(6)} = [1,1]$, $x^{(7)} = [1,2]$, $x^{(8)} = [0,0]$
- 已知 $x^{(1)}, x^{(2)}, x^{(3)}, x^{(4)}$ 属于类别A, $x^{(5)}, x^{(6)}, x^{(7)}$ 属于类别B。
- 计算样本 $x^{(8)}$ 到其他样本的欧式距离
- 使用K近邻算法, 距离采用欧式距离, 令K=1, 预测 $x^{(8)}$ 的类别
- 使用K近邻算法, 距离采用欧式距离, 令K=3, 预测 $x^{(8)}$ 的类别

- $x^{(1)} = [1,0]$, $x^{(2)} = [3,0]$, $x^{(3)} = [0,3]$, $x^{(4)} = [-2,-2]$,
 - $x^{(5)} = [2,0]$, $x^{(6)} = [1,1]$, $x^{(7)} = [1,2]$, $x^{(8)} = [0,0]$
- $x^{(1)}, x^{(2)}, x^{(3)}, x^{(4)}$ 属于类别A, $x^{(5)}, x^{(6)}, x^{(7)}$ 属于类别B

1. 计算待预测样本 $x^{(8)}$ 与训练样本的欧式距离

- $d_{18} = 1$, $d_{28} = 3$, $d_{38} = 3$, $d_{48} = 2\sqrt{2} = 2.828$,
- $d_{58} = 2$, $d_{68} = \sqrt{2} = 1.414$, $d_{78} = \sqrt{5} = 2.236$

2. 排序: $d_{18} < d_{68} < d_{58} < d_{78} < d_{48} < d_{28} = d_{38}$

3. 取前k(=3)个距离最近样本, 统计其类别:

样本1、6、5; 类别分别为A、B、B

4. 将占比最多的类别赋给待预测样本: 类别B

实验用数据集

花萼 长度	花萼 宽度	花瓣 长度	花瓣 宽度	类别
				0、1、2

学
ITY

- Iris 数据集：鸢尾花卉数据集
- 150个样本，分为3类，每类50个数据：每行一个样本
- Data:1-4列为：花萼长度，花萼宽度，花瓣长度，花瓣宽度
- Target: 鸢尾花的类别（Setosa, Versicolour, Virginica三类）

```
from sklearn.datasets import load_iris  
  
data = load_iris()  
X = data.data  
y = data.target
```


- 数据集划分为：训练集和测试集
- 选择一个K
- 对于测试集的样本 x ，计算其与训练集中所有样本的距离
- 对距离进行排序，选择前K个邻居，统计其类别
- 将多数类赋予 x

- 比较预测结果和真实标签，计算预测准确率

如何选择K

- 采用s折交叉验证 ($s=5$)
- 将训练集分成5份，其中一份为验证集，其他为训练集，共5种
- 每一种分法，对所有的k，使用knn，并计算准确率
- 对5种分法，准确率取平均
- 选择准确率最高的k


- 实验零：看懂代码（百度，懂得越多，写的越快）
- 实验1.1：使用print功能观察数据
- 实验1.2：调整画图函数的参数
- 扩展实验1.3：距离更改为曼哈顿距离的代码

实验报告要求

- 实验结束**7天内**提交实验报告
 - 砺儒云平台提交
 - 简洁（1-2页即可）
 - 基本原理
 - 实验1.1, 1.2 关键代码（需要解释每行代码的功能），1.3选作
 - 实验结果（需要对实验结果进行描述和分析）
- **杜绝抄袭，如有发现，按零分计**

实验2：决策树

谁在买计算机？



计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

如何衡量特征的重要性 信息增益

- 考虑特征能够为分类系统带来多少信息
- 带来的信息越多，该特征越重要
- 如何度量信息量的大小？
- 在物理学中，熵度量一个热力学系统的无序程度
- 在信息学中，信息熵是对不确定性（信息）的度量

信息量 – 单个事件

- 信源发什么符号（事件）是不确定的，可概率来度量
- 事件概率大，出现机会多，不确定性小，事件发生带来的信息量小
- 事件概率小，出现机会小，不确定性大，事件发生带来的信息量大
- 信息量函数 f 是概率 P 的减函数
- 两个独立符号（独立事件）产生的信息量应满足可加性

$$f(P_1, P_2) = f(P_1) + f(P_2)$$

- 函数 $f(P) = \log \frac{1}{P} = -\log P$ 满足要求

信息熵 - 随机事件


- 信息熵：信源的平均信息量（不确定性）
- 单个符号（事件）信息量（不确定性）的均值

$$H(X) = E[-\log_2 P] = \sum_{i=1}^N -P \log_2 P$$

- 对于**分类系统**来说，事件：属于什么类别
- 熵就可以表示为：

$$H(U) = \sum_{i=1}^N -P(C_i) \log_2 P(C_i), P(C_i) \text{ 为类别为 } i \text{ 的概率}$$

含义：？



- 设有随机变量 (X, Y) , 其联合概率分布为:

$$P(X = x_i, Y = y_j) = p_{ij}, \quad i = 1, 2, \dots, n; \quad j = 1, 2, \dots, m$$

- 条件熵 $H(Y|X)$: 表示在已知随机变量 X 的条件下随机变量 Y 的不确定性, 定义为 X 给定条件下 Y 的条件概率分布的熵对 X 的数学期望:

$$H(Y|X) = \sum_{i=1}^n p_i H(Y|X = x_i)$$

信息增益 information gain

- 针对一个特征而言,
- 有没有这个特征信息熵的差, 就是这个特征给系统带来的信息量

$$IG(S, A) = \text{Entropy}(S) - \text{Entropy}(S|A)$$

$$= \text{Entropy}(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} \text{Entropy}(S_v)$$

- $\text{Values}(A)$ 是属性 A 所有可能值的集合
- S_v 是 S 中属性 A 的值为 v 的子集 ($S_v = \{s \in S \mid A(s) = v\}$)

ID3算法 Iterative Dichotomiser 3

- 核心思想：信息增益越大，区分样本的能力就越强
 - 在决策树的每一个非叶子结点划分之前，**先计算每一个属性所带来的信息增益，选择最大信息增益的属性来划分**，直到信息增益很小或者没有特征可以选择为止。

信息增益如何计算

- 输入：训练数据集D和特征A;
- 输出：特征A对训练数据集D的信息增益 $g(D,A)$
- 1、计算数据集D的经验熵 $H(D)$

$$H(D) = - \sum_{k=1}^K \frac{|C_k|}{|D|} \log_2 \frac{|C_k|}{|D|}$$

- 2、计算特征A对数据集D的经验条件熵 $H(D|A)$

$$H(D|A) = \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i) = - \sum_{i=1}^n \frac{|D_i|}{|D|} \sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log_2 \frac{|D_{ik}|}{|D_i|}$$

- 3、计算信息增益 $g(D,A) = H(D) - H(D|A)$

- 以信息增益作为划分训练数据集的特征，存在偏向于选择取值较多的特征的问题，使用信息增益比可以对这一问题进行校正
- 定义5.3（信息增益比） 特征A对训练数据集D的信息增益比定义为信息增益与训练数据集D关于特征A的值的熵之比

$$g_R(D, A) = \frac{g(D, A)}{H_A(D)}$$

$$H_A(D) = - \sum_{i=1}^n \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|}, \text{ } n \text{ 是特征 } A \text{ 取值的个数。}$$

数据集

- 有8个数据，每个数据有5个特征，属于两个类别：Y、N

	A	B	C	D	E	F
1	Age	Sex	Major	Mid-term	Attendance	Pass
2	Old	F	Education	Low	Low	Y
3	Young	M	Physics	Low	Low	N
4	Old	F	Physics	High	High	Y
5	Old	M	Physics	High	High	Y
6	Young	M	Education	High	High	Y
7	Old	F	Education	High	High	Y
8	Young	F	Physics	High	Low	Y
9						

ID3算法的实现过程

- 实验中，只选择了一次节点
- 1. 计算整个数据集的熵（按照分类标签计算）
- 2. 对于每一种特征，计算条件熵
 - 对数据集按照该特征取值不同进行split
 - 每个子集计算熵
 - 按照子集的比例进行加权求和
- 3. 计算信息增益，取最大信息增益的特征

- 实验零：看懂代码
- 使用print功能观察中间运行结果，辅助看懂代码
- 实验2.1：ID3算法（计算条件熵，信息增益）
- 实验2.2（扩展）：C4.5算法

实验报告要求

- 实验结束**7天内**提交实验报告
 - 砺儒云平台提交
 - 简洁（1-2页即可）
 - 基本原理
 - 关键代码（需要解释每行代码的功能）
 - 实验结果（需要对实验结果进行描述和分析）
- **杜绝抄袭，如有发现，按零分计**