


第二次实验：无监督学习

- 无监督学习简介
- 聚类
- 降维

- 聚类 (clustering) 是将样本集合中相似的样本归为相同的类，不相似的样本分配到不同的类。
- 聚类时，样本通常是欧氏空间中的向量，类别是从数据中自动发现，但类别的个数通常是事后的相似度或距离由应用决定。



- 聚类 (clustering) 是针对给定的样本，依据它们特征的相似度或距离，将其归并到若干个“类”或“簇”。
- 相似的样本聚集在相同的类；不相似的样本分散在不同的类
- 相似度或距离如何定义？
- 如何进行聚类？
 - 层次聚类
 - k均值聚类

- 当 $p=2$ 时称为欧氏距离 (Euclidean distance)

$$d_{ij} = \left(\sum_{k=1}^m |x_{ki} - x_{kj}|^2 \right)^{\frac{1}{2}}$$

- 当 $p=1$ 时称为曼哈顿距离 (Manhattan distance)

$$d_{ij} = \sum_{k=1}^m |x_{ki} - x_{kj}|$$

- 当 $p=\infty$ 时称为切比雪夫距离 (Chebyshev distance)

$$d_{ij} = \max_k |x_{ki} - x_{kj}|$$

k均值聚类算法

输入: n 个样本的集合 X ;

输出: 样本集合的聚类 C^* 。

(1) 初始化。令 $t = 0$, 随机选择 k 个样本点作为初始聚类中心 $m^{(0)} = (m_1^{(0)}, \dots, m_l^{(0)}, \dots, m_k^{(0)})$ 。

(2) 对样本进行聚类。对固定的类中心 $m^{(t)} = (m_1^{(t)}, \dots, m_l^{(t)}, \dots, m_k^{(t)})$, 其中 $m_l^{(t)}$ 为类 G_l 的中心, 计算每个样本到类中心的距离, 将每个样本指派到与其最近的中心的类中, 构成聚类结果 $C^{(t)}$ 。


(3) 计算新的类中心。对聚类结果 $C^{(t)}$, 计算当前各个类中的样本的均值, 作为新的类中心 $m^{(t+1)} = (m_1^{(t+1)}, \dots, m_l^{(t+1)}, \dots, m_k^{(t+1)})$ 。

(4) 如果迭代收敛或符合停止条件, 输出 $C^* = C^{(t)}$ 。

否则, 令 $t = t + 1$, 返回步 (2)。

k 均值聚类算法的复杂度是 $O(mnk)$, 其中 m 是样本维数, n 是样本个数, k 是类别个数。

动画展示 k均值聚类



主成分分析 (principal component analysis, PCA)




- 无监督学习方法
- 最常用的降维方法

$$z = Wx$$

- 利用**正交变换**把由线性相关变量表示的观测数据转换为少数几个由线性无关变量表示的数据，线性无关的变量称为主成分。
- 主成分的个数通常小于原始变量 的个数，所以主成分分析属于降维方法。
- 主成分分析主要用于发现数据中的基本结构， 即数据中变量之间的关系。

● 几何意义

- 坐标轴转换
- Orthogonal coordinate axes
- 样本点均匀分散



最大可分性总结

- 样本点在这个超平面上的投影的方差最大
- 只需要对协方差矩阵进行特征值分解，将求得的特征值进行排序

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d$$

- 取前 d' 个特征值对应的特征向量构成 W

- Step 1: 计算平均值 $\mu = \frac{1}{n} \sum_{i=1}^n x_i$
- Step 2: 零均值 $\tilde{X} = X - \mu$
- Step 3: 构建互相关矩阵 $V = \frac{1}{n} \tilde{X} \tilde{X}^T$
- Step 4: 特征值分解, 得到特征值 λ_i 和特征向量 w_i , 且降序排列特征值 λ_i
- Step 5: 根据贡献率, 选择 d 特征值 $\Lambda = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_d]$ 和特征向量 $W_d = [W_1, W_2, \dots, W_d]$, 所以 $F = W_d^T \tilde{X}$

- 贡献率: 信息抽取

- 贡献率: λ_i 是成分i的特征值 $\alpha_i = \lambda_i / \sum_{i=1}^p \lambda_i$

- 累积贡献率: $M_k = \sum_{i=1}^k \lambda_i / \sum_{i=1}^p \lambda_i$

- 常见的累积贡献率一般大于 80%

- 实验零：看懂代码（百度，懂得越多，写的越快）
- 实验一：计算中心点
- 实验二：print出中心点，观察中心点在迭代中的变化
- 实验三：观察不同的K对聚类结果的影响
- 实验四（扩展）：补充完整PCA代码（计算协方差矩阵、特征值、特征向量）

实验报告要求

- 实验结束**7天内**提交实验报告
 - 砺儒云平台提交
 - 简洁（1-2页即可）
 - 基本原理
 - 关键代码（需要解释每行代码的功能）
 - 实验结果（需要对实验结果进行描述和分析）
- **杜绝抄袭，如有发现，按零分计**